

UNIVERSIDAD AUTÓNOMA DE
YUCATÁN

MAESTRÍA EN CIENCIAS DE LA
COMPUTACIÓN

Aprendizaje Automático

Reporte Ejercicio 5

WILLIAM FELIPE CETINA PECH

21 de Mayo del 2026

En este reporte se resumirá varios experimentos con modelos K-Medias

Base de datos

La base de datos a utilizar será la de Wholesale customers data.csv, un dataset que consta de 440 muestras, cada una contiene 8 valores, siendo estos productos que compra el cliente. Siendo estos Channel, Region, Fresh, Mil, Grocery, Frozen, Detergents_Paper y Delicassen. Para este proceso solo se tomarán en cuenta las características que involucren el gasto, por lo que Channel y Region serán descartadas

K-Means


En este reporte se realizarán experimentos para buscar la cantidad acertada de K-Means para subdividir el muestreo de clientes, por cada modelo K-Means evaluado se obtendrá

Inercia: Valor indicador de que tan lejos los puntos se encuentran de su centroide en promedio

Centroide: Los centroides finales definidos tras realizar el procedimiento


Etiquetas: Mapeo de las etiquetas finales de las tuplas (Cada cliente a que cluster pertenece)

El valor K definirá cuántos grupos totales queremos formar, en este experimento se analizará para K = 2, 3, 4 y 5. En base a su inercia se definirá cual es el K óptimo a elegir para el modelo final. Para esto utilizaremos el método del codo el cual es un análisis visual de la inercia de todas las K donde el momento en donde más se vea una curvatura es la que esta técnica sugiere ser el mejor. Una vez corrido el experimento los resultados indican:



Analizando la gráfica aquella que presenta más inclinación entre sus conexiones es cuando K=2, por lo que se define K=2 como el ideal para este contexto. A pesar de que 5 tiene menos inercia esto se puede deber a por ser más centroides esparcidos

A continuación se realizará el gráfico final para ver la distribución de las muestras en los K-grupos seleccionados (2). Dado que los datos son de 6 dimensiones es imposible graficar en la computadora dichas dimensiones por lo que se utilizara PCA el cual es un técnica matemática que reduce la dimensión perdiendo la menor cantidad posible de información de las dimensiones originales. Utilizando PCA reducimos la dimensión a solo 2, pudiendo visualizar de tal forma la siguiente figura.



En esta podemos apreciar como ahora los 2 grupos fueron segmentados y los centroides propuesto siendo los siguientes:

Centroide 1: [-0.00670029 -0.21151984 -0.23455562 -0.03442131 -0.23360924
-0.09446257]

Centroide 2: [0.06349325 2.00440225 2.22269372 0.32618292 2.2137257 0.8951453]